

TimeRole 相关时间序列预测文献综述

从 Neurocomputing 种子论文到 Mamba/SSM、长历史记忆、检索增强与预测修正

文献池：73 篇（已标准化去重）

版本日期：2026-08-26

用途说明

本报告用于论文写作、Related Work 组织和 TimeRole 创新边界判断。它不是系统综述或正式 meta-analysis。A 级来源为用户上传全文；B 级为本轮通过官方出版社/会议/预印本页面核对；C 级为从 5 篇种子论文参考文献中筛出的工作，主要做文献定位与方法边界总结，正式引用前建议再阅读全文核对。

1. 执行摘要：当前文献地图与 TimeRole 的可用创新空间

经过标准化与去重，本报告整理 73 篇核心/观察文献，其中 5 篇为用户上传的 Neurocomputing 种子论文，39 篇来自这些论文的参考文献池，13 篇补齐 Mamba/SSM 与长历史有效窗口，8 篇补齐 retrieval/memory/refinement 路线，并在最终核验时新增 3 篇 2025 年 NeurIPS 高相关工作。

文献已非常拥挤的方向包括：多尺度 Patch、trend/seasonal 或 high/low frequency 分解、local/global 双分支、Graph+Mamba/SSM、外部历史检索、generic base forecast + residual/refinement。单独将这些作为 TimeRole 主创新，审稿风险较高。

仍有相对清晰的定位空间：把同一输入历史按时间位置区分为 recent predictive state 与 distant corrective evidence；近期历史负责建立 primary forecast，远期历史不与其对称竞争，而是在近期状态条件下仅对可能存在的预测偏差进行修正。核心关键词应是 asymmetric forecasting responsibility，而不是 long/short branch。

最关键的直接竞争工作目前是 DualNet、PFRP、Attraos、MEW、MCNet、Multi-Granularity Residual Learning、xLSTM-Mixer、Stratify、PIR、HiLIN、Pathformer。论文方法与 Introduction 必须明确逐一绕开这些已有概念。

1.1 文献来源与可信度标记

来源级别	含义	数量	使用建议
A	已上传全文，直接阅读并总结	5	可直接用于细节比较
B	官方/会议/出版社/预印本页面已核对	29	可用于方法定位与元数据
C	来自种子论文 References，未在本报告中逐篇重读全文	39	正式写作前重点论文需再精读

1.2 六条主要研究路线

路线	代表工作	对 TimeRole 的意义
LTSF / MTSF 基础骨架	DLinear、PatchTST、iTransformer、Crossformer、Informer、Autoformer、FEDformer、TimesNet、TimeMixer	构成 Introduction 与 baseline 的公共引用骨架。
多尺度 / Local-Global / Decomposition	LSTNet、MICN、Pathformer、MTST、AMD、MSPatch、HiLIN、AweHF	证明“不同尺度/成分分别建模”已高度成熟。
Graph / Inter-variable Modeling	MTGNN、Graph WaveNet、AGCRN、DiM、SSMGNN、G-Mamba	若近期主干保留 Graph，这些工作决定创新边界。
Mamba / SSM	S4、SpaceTime、S-Mamba、TimeMachine、ms-Mamba、MambaTS、WaveletMamba	Mamba 只能作为 backbone/实现选择，难以再单独承担主创新。
Long History / Memory / Retrieval	Attraos、MEW、PFRP、RAFT、TimeRAF、SARAF、GeMeR-TS	该路线与“如何利用远历史”最接近，是 TimeRole 的核心文献背景。
Forecast Correction / Revision	DualNet、MRLF、xLSTM-Mixer、Stratify、GARS、PIR	“基础预测 + 修正”也已形成明确路线；创新需落在修正来源、触发

2. 全部文献总表

优先级：P0=直接竞争/必须精读；P1=必读或强建议引用；P2=建议；P3=补充或观察。风险表示与 TimeRole 当前构想的概念重叠风险。

编号	论文	年份	期刊/会议	主类别	优先级	风险
S1	Wrinkles in time: Multi-scale patching and super-resolution for efficient time series forecasting	2026	Neurocomputing 676, 133021	种子论文/分解与多尺度	P1	中
S2	DiM: Improving multivariate time series forecasting with DI embedding and multi-head graph learning mechanism	2026	Neurocomputing 659, 131777	种子论文/变量关系	P2	低
S3	DualNet: A dual-path network with adaptive compensation for multivariate time series forecasting	2025	Neurocomputing 649, 130720	种子论文/补偿预测	P0	高
S4	Multi-resolution Patch-based Fourier Graph Spectral Network for spatiotemporal time series forecasting	2025	Neurocomputing 638, 130132	种子论文/多分辨率图	P1	中
S5	Adaptive wavelet decomposition and event-aware high-frequency modeling network for multivariate time series forecasting	2026	Neurocomputing 676, 133089	种子论文/趋势-事件分工	P0	高
1	Are Transformers Effective for Time Series Forecasting? (DLinear)	2023	AAAI	LTSF 基础	P1	低
2	Crossformer: Transformer Utilizing Cross-Dimension Dependency for Multivariate Time Series Forecasting	2023	ICLR	LTSF 基础/跨变量	P1	低
3	A Time Series is Worth 64 Words: Long-term Forecasting with Transformers (PatchTST)	2023	ICLR	LTSF 基础/Patch	P1	中
4	iTransformer: Inverted Transformers Are Effective for Time	2024	ICLR	LTSF 基础/变量	P1	低

	Series Forecasting					
5	Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting	2021	NeurIPS	分解	P1	中
6	FEDformer: Frequency Enhanced Decomposed Transformer for Long-Term Series Forecasting	2022	ICML	频域/分解	P2	低
7	Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting	2021	AAAI	LTSF 基础	P2	低
8	TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis	2023	ICLR	多周期/CNN	P2	低
9	TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting	2024	ICLR	多尺度/MLP	P1	中
10	MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting	2024	AAAI	多尺度/变量关系	P2	低
11	Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks (LSTNet)	2018	ACM SIGIR	长短模式	P0	高
12	MICN: Multi-scale Local and Global Context Modeling for Long-term Series Forecasting	2023	ICLR	Local-Global	P0	高
13	Rethinking Decomposition for Time Series Forecasting: Learning from Temporal Patterns	2025	Expert Systems with Applications 287, 128044	分解/模式专门化	P0	高
14	Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting	2024	ICLR	多尺度/自适应路径	P0	高
15	Multi-Resolution Time-Series Transformer for Long-Term Forecasting (MTST)	2024	AISTATS, PMLR 238	多分辨率	P1	中
16	SOFTS: Efficient Multivariate Time Series Forecasting	2024	NeurIPS	变量融合/轻量	P2	低

	with Series-Core Fusion					
17	TimeSQL: Improving Multivariate Time Series Forecasting with Multi-Scale Patching and Smooth Quadratic Loss	2024	Information Sciences 671, 120652	多尺度/Patch	P1	中
18	TSMixer: An All-MLP Architecture for Time Series Forecasting	2023	arXiv:2303.06053 (种子论文引用版本)	MLP 基线	P2	低
19	TSMixer: Lightweight MLP-Mixer Model for Multivariate Time Series Forecasting	2023	ACM SIGKDD	MLP 基线	P3	低
20	Adaptive Multi-Scale Decomposition Framework for Time Series Forecasting (AMD)	2025	AAAI	多尺度/分解	P1	中
21	MSPatch: A Multi-Scale Patch Mixing Framework for Multivariate Time Series Forecasting	2025	Expert Systems with Applications 273, 126849	多尺度/Patch	P1	中
22	A Multi-Scale Decomposition MLP-Mixer for Time Series Analysis (MSD-Mixer)	2024	PVLDB 17(7), 1723-1736	多尺度/MLP	P2	低
23	WPMixer: Efficient Multi-Resolution Mixing for Long-Term Time Series Forecasting	2025	AAAI	小波/多分辨率	P2	中
24	HDMixer: Hierarchical Dependency with Extendable Patch for Multivariate Time Series Forecasting	2024	AAAI	Patch/CNN	P3	低
25	MTS-Mixers: Multivariate Time Series Forecasting via Factorized Temporal and Channel Mixing	2023	arXiv:2302.04501	MLP/变量	P3	低
26	FITS: Modeling Time Series with 10k Parameters	2023	arXiv:2307.03756	频域/轻量	P2	低
27	Frequency-Domain MLPs Are More Effective Learners in Time Series Forecasting	2023	NeurIPS 2023 (Advances in NIPS 36)	频域/MLP	P3	低
28	TF4TF: Multi-Semantic Modeling within the Time-Frequency Domain	2025	Neurocomputing 617, 128913	时频/Transformer	P2	低

	for Long-Term Time-Series Forecasting					
29	DeformableTST: Transformer for Time Series Forecasting without Over-Reliance on Patching	2024	NeurIPS	Transformer/Patch 反思	P1	中
30	High-Low Frequency Dynamic Interactive Fusion Network for Multivariate Time Series Forecasting (HiLIN)	2025	Knowledge-Based Systems 310, 112951	高低频分工	P0	高
31	Multi-Granularity Residual Learning with Confidence Estimation for Time Series Prediction	2022	The Web Conference (WWW)	残差/多粒度	P0	高
32	Connecting the Dots: Multivariate Time Series Forecasting with Graph Neural Networks (MTGNN)	2020	ACM SIGKDD	Graph/MTS	P1	低
33	Graph WaveNet for Deep Spatial-Temporal Graph Modeling	2019	IJCAI	Graph/时空	P2	低
34	Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting (AGCRN)	2020	NeurIPS	Graph/自适应	P2	低
35	Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting (STGCN)	2018	IJCAI	Graph/时空	P3	低
36	Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting (DCRNN)	2018	ICLR	Graph/RNN	P3	低
37	Global-Local Feature Learning via Dynamic Spatial-Temporal Graph Neural Network in Meteorological Prediction	2024	IEEE Transactions on Knowledge and Data Engineering	Global-Local/ Graph	P2	中
38	M2AST: MLP-Mixer-Based Adaptive Spatial-Temporal	2024	Multimedia Systems 30(4), 206	Graph/Mixer	P3	低

	Graph Learning for Human Motion Prediction					
39	Spatial-Temporal Identity: A Simple yet Effective Baseline for Multivariate Time Series Forecasting (STID)	2022	ACM CIKM	简单时空基线	P2	低
40	Mamba: Linear-Time Sequence Modeling with Selective State Spaces	2023	arXiv:2312.00752	Mamba/SSM	P1	中
41	Efficiently Modeling Long Sequences with Structured State Spaces (S4)	2022	ICLR	SSM 基础	P2	低
42	Effectively Modeling Time Series with Simple Discrete State Spaces (SpaceTime)	2023	ICLR	SSM/时间序列	P2	低
43	Is Mamba Effective for Time Series Forecasting? (S-Mamba)	2025	Neurocomputing 619, 129178	Mamba/MTS	P1	中
44	TimeMachine: A Time Series is Worth 4 Mambas for Long-Term Forecasting	2024	ECAI 2024, FAIA 392:1688-1695	Mamba/多尺度	P1	高
45	ms-Mamba: Multi-scale Mamba for Time-Series Forecasting	2026	Neurocomputing 680, 133226	Mamba/多尺度	P0	高
46	SSMGNN: Spectral Temporal Graph Neural Network with State Space Models for Multivariate Time-Series Forecasting	2026	Neurocomputing 666, 132295	SSM/Graph	P0	高
47	Graph-Enhanced Mamba: Efficient Spatiotemporal Sequence Modeling with Selective State Space and Graph Neural Networks	2026	Neurocomputing 680, 133280	Mamba/Graph	P0	高
48	Attractor Memory for Long-Term Time Series Forecasting: A Chaos Perspective (Attraos)	2024	NeurIPS	Historical Memory	P0	高
49	Enhancing the Maximum Effective Window for Long-Term Time Series Forecasting	2025	NeurIPS	长历史/有效窗口	P0	高
50	MambaTS: Improved	2026	Pattern Recognition,	Mamba/MTS	P1	中

	Selective State Space Models for Long-Term Time Series Forecasting		article 114536			
51	WaveletMamba: Harnessing Learnable Multi-Scale State Space Dynamics for Time Series Forecasting	2026	Neural Networks 204, 109296	Mamba/频率多尺度	P1	高
52	Transformers Are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality (Mamba-2)	2024	ICML, PMLR 235	SSM 理论	P3	低
53	Predicting the Future by Retrieving the Past (PFRP)	2026	AAAI 2026, 40(25):20896-20904	历史检索	P0	高
54	Retrieval Augmented Time Series Forecasting (RAFT)	2025	ICML, PMLR 267:21774-21797	历史检索	P0	高
55	TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting	2025	IEEE Transactions on Knowledge and Data Engineering	历史检索/基础模型	P1	中
56	Retrieval-Augmented Diffusion Models for Time Series Forecasting (RATD)	2024	NeurIPS	历史检索/生成	P1	中
57	Stationarity-Aware Retrieval-Augmented Time Series Forecasting (SARAF)	2026	KDD 2026 (Research Track, accepted/in press)	历史检索/非平稳	P0	高
58	GeMeR-TS: Generative Memory-Based Retrieval and Mixture-of-Experts for Cross-Domain Time-Series Forecasting	2026	IEEE Transactions on Big Data 12(4):1401-1419	Memory/Retrieval	P1	中
59	xLSTM-Mixer: Multivariate Time Series Forecasting by Mixing via Scalar Memories	2025	NeurIPS	Forecast Refinement	P0	高
60	MCNet: Multivariate Long-Term Time Series Forecasting with Local and Global Context Modeling	2024	Information Sciences 676, 120864	Local-Global	P0	高
61	Stratify: Unifying Multi-Step Forecasting Strategies	2025	Data Mining and Knowledge Discovery 39, article 64	Residual Rectification	P0	高

62	GARS: Gap-Aware Residual Selection for Long-Horizon Time-Series Forecasting	2026	Preprints.org, posted 2026-08-04	Residual Correction	P0	高
63	Retrieval Augmented Forecasting (RAF)	2024	arXiv:2411.08249	历史检索/基础模型	P3	中
64	Semantics-Enhanced Retrieval-Augmented Time Series Forecasting (SERAF)	2026	arXiv:2606.14941	历史检索/语义	P3	中
65	Model-Agnostic Retrieval-Augmented Extended Forecasting for Time Series (RAEF)	2026	arXiv:2608.14054	历史检索/模型无关	P3	中
66	Improving Time Series Forecasting via Instance-Aware Post-hoc Revision (PIR)	2025	NeurIPS	Post-hoc Revision	P0	高
67	How Different from the Past? Spatio-Temporal Time Series Forecasting with Self-Supervised Deviation Learning (ST-SSDL)	2025	NeurIPS	Historical Deviation	P1	中
68	DecompNet: Enhancing Time Series Forecasting Models with Implicit Decomposition	2025	NeurIPS	分解增强	P2	低

3. 逐篇摘要与 TimeRole 关系

下列摘要重点不是复述每篇论文全部技术细节，而是提取“它解决什么问题、用了什么核心思路、它如何限制或支持 TimeRole 的创新定位”。

3.1 Neurocomputing 种子论文

[S1] Wrinkles in time: Multi-scale patching and super-resolution for efficient time series forecasting

2026 | Neurocomputing 676, 133021 | 种子论文/分解与多尺度 | P1 | 风险：中 | 来源级别：A

DOI/标识：10.1016/j.neucom.2026.133021

问题：兼顾长序列预测精度与计算效率，并解决轻量 MLP 对局部周期和长期趋势刻画不足的问题。

核心方法：移动平均分解得到 seasonal/trend；seasonal 采用多尺度 2D patch + CNN，trend 采用 SSSD 式超分辨率，再由 MLP 预测并重组。

对 TimeRole 的意义：证明“不同时间信息应采用差异化建模”已是成熟思路；TimeRole 需从 signal-component differentiation 转向 historical-role differentiation。

[S2] DiM: Improving multivariate time series forecasting with DI embedding and multi-head graph learning mechanism

2026 | Neurocomputing 659, 131777 | 种子论文/变量关系 | P2 | 风险：低 | 来源级别：A

DOI/标识：10.1016/j.neucom.2025.131777

问题：同时增强时间动态表达与动态跨变量依赖建模。

核心方法：Difference-Inverted embedding 补偿 inverted embedding 的时间动态不足；multi-head graph learning 学习多组可适应图结构，并嵌入 MetaFormer。

对 TimeRole 的意义：如果 TimeRole 的近期主干保留图结构，DiM 说明动态图/多头图本身已不足以构成主创新。

[S3] DualNet: A dual-path network with adaptive compensation for multivariate time series forecasting

2025 | Neurocomputing 649, 130720 | 种子论文/补偿预测 | P0 | 风险：高 | 来源级别：A

DOI/标识：10.1016/j.neucom.2025.130720

问题：统一端到端预测难以同时兼顾全局演化与关键局部变化。

核心方法：将预测拆为 primary trajectory estimator 与 residual compensation，两路径通过温度缩放的动态权重自适应平衡。

对 TimeRole 的意义：与“主预测 + 修正”高度接近；TimeRole 必须强调修正信息来自 distant history 且职责从属于 recent-state primary forecast。

[S4] Multi-resolution Patch-based Fourier Graph Spectral Network for spatiotemporal time series forecasting

2025 | Neurocomputing 638, 130132 | 种子论文/多分辨率图 | P1 | 风险：中 | 来源级别：A

DOI/标识：10.1016/j.neucom.2025.130132

问题：多分辨率时空关联分析不足，同时传统图运算效率较低。

核心方法：多分辨率 patch + hyperpatch graph + Fourier Graph Spectral Network，并以 residual fusion 融合不同尺度。

对 TimeRole 的意义：直接覆盖“多分辨率 Patch + Graph + residual fusion”；不宜把这些模块作为 TimeRole 的主要新颖性。

[S5] Adaptive wavelet decomposition and event-aware high-frequency modeling network for multivariate time series forecasting

2026 | Neurocomputing 676, 133089 | 种子论文/趋势-事件分工 | P0 | 风险：高 | 来源级别：A

DOI/标识：10.1016/j.neucom.2026.133089

问题：非平稳序列中长期趋势与突发高频事件耦合，固定分解和统一建模难以适应。

核心方法：Adaptive Wavelet Decomposition 分离低频趋势/高频事件；趋势用 MLP，高频事件用 TAN + DSPGC，再双向交互融合。

对 TimeRole 的意义：与 TimeRole 都强调“异质信息分工”，但 AweHF 是 frequency-defined role，TimeRole 应是 history-position-defined role。

3.2 LTSF / MTSF 基础与轻量骨架

[1] Are Transformers Effective for Time Series Forecasting? (DLinear)

2023 | AAAI | LTSF 基础 | P1 | 风险：低 | 来源级别：C

问题：复杂 Transformer 在多个 LTSF 基准上未必优于简单模型。

核心方法：以分解后的简单线性映射构造 DLinear/NLinear，系统反思 Transformer 的必要性。

对 TimeRole 的意义：TimeRole 的近期主干应保持足够简洁，并用此类强简单基线验证“职责机制”而非模型体量带来的增益。

[2] Crossformer: Transformer Utilizing Cross-Dimension Dependency for Multivariate Time Series Forecasting

2023 | ICLR | LTSF 基础/跨变量 | P1 | 风险：低 | 来源级别：C

问题：传统时间序列 Transformer 对跨变量依赖建模不足。

核心方法：采用 dimension-segment-wise embedding 与 two-stage attention 同时建模时间和变量维度。

对 TimeRole 的意义：属于 MTSF 基础必引；主要约束变量交互创新，不直接覆盖 historical responsibility。

[3] A Time Series is Worth 64 Words: Long-term Forecasting with Transformers (PatchTST)

2023 | ICLR | LTSF 基础/Patch | P1 | 风险：中 | 来源级别：C

问题：点级 token 计算成本高，且难以充分利用更长历史。

核心方法：按通道独立切 patch，将子序列作为 token，从而降低 token 数并扩大有效历史窗口。

对 TimeRole 的意义：是 TimeRole 历史切分/patch 设计的基础边界：仅靠长短 patch 不足以构成创新。

[4] iTransformer: Inverted Transformers Are Effective for Time Series Forecasting

2024 | ICLR | LTSF 基础/变量 | P1 | 风险：低 | 来源级别：C

问题：经典 Transformer 的 token 定义不利于变量级相关性学习。

核心方法：将整条变量序列视为 token，注意力在 variate tokens 间学习相关性。

对 TimeRole 的意义：应作为 multivariate backbone 强基线；若近期分支做变量交互，需要与其比较。

[5] Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting

2021 | NeurIPS | 分解 | P1 | 风险：中 | 来源级别：C

问题：长序列中的趋势/周期性与长期依赖难以同时处理。

核心方法：将 series decomposition 作为内部模块，并用 Auto-Correlation 代替标准注意力。

对 TimeRole 的意义：说明 trend-seasonal decomposition 已非常成熟，TimeRole 不应把普通分解作为核心贡献。

[6] FEDformer: Frequency Enhanced Decomposed Transformer for Long-Term Series Forecasting

2022 | ICML | 频域/分解 | P2 | 风险：低 | 来源级别：C

问题：长期预测需同时处理分解结构和频域稀疏特征。

核心方法：结合分解与频域增强的稀疏表示来降低复杂度并提升长期预测。

对 TimeRole 的意义：限制“频域 + 分解”创新空间，可作为频率角色分工的背景。

[7] Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting

2021 | AAAI | LTSF 基础 | P2 | 风险：低 | 来源级别：C

问题：标准 self-attention 在长序列上的二次复杂度过高。

核心方法：ProbSparse attention 与 distilling 机制降低长序列计算负担。

对 TimeRole 的意义：属于长序列预测经典背景，主要用于 Introduction。

[8] TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis

2023 | ICLR | 多周期/CNN | P2 | 风险：低 | 来源级别：C

问题：一维时间序列中的多周期与周期内/周期间变化难以统一建模。

核心方法：将 1D 序列映射到多周期 2D 表示，用 2D convolution 捕获 intra/inter-period variation。

对 TimeRole 的意义：限制“2D 周期表示”创新；与 TimeRole 核心职责机制差异较大。

[9] TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting

2024 | ICLR | 多尺度/MLP | P1 | 风险：中 | 来源级别：C

问题：单尺度表示难以同时覆盖微观变化和宏观趋势。

核心方法：构造多尺度序列并进行 past-decomposable mixing / future-multipredictor mixing。

对 TimeRole 的意义：非常重要的多尺度基线；TimeRole 必须区别“scale-wise parallel evidence”和“asymmetric responsibility”。

[16] SOFTS: Efficient Multivariate Time Series Forecasting with Series-Core Fusion

2024 | NeurIPS | 变量融合/轻量 | P2 | 风险：低 | 来源级别：C

问题：需要在低复杂度下有效汇聚变量间共同信息。

核心方法：以 series-core fusion 形成轻量跨变量交互。

对 TimeRole 的意义：适合作为近期主干的轻量替代方案，帮助避免 Graph-Mamba 过度堆叠。

[18] TSMixer: An All-MLP Architecture for Time Series Forecasting

2023 | arXiv:2303.06053 (种子论文引用版本) | MLP 基线 | P2 | 风险：低 | 来源级别：C

问题：探讨不依赖 attention 的纯 MLP 是否足以进行时间序列预测。

核心方法：沿时间/特征维度进行 MLP mixing，结构简单高效。

对 TimeRole 的意义：适合作为轻量近期主干参照，证明 TimeRole 增益来自职责机制而非复杂 backbone。

[19] TSMixer: Lightweight MLP-Mixer Model for Multivariate Time Series Forecasting

2023 | ACM SIGKDD | MLP 基线 | P3 | 风险：低 | 来源级别：C

问题：降低多变量预测模型复杂度并保持竞争性能。

核心方法：使用轻量 MLP-Mixer 对时间和变量信息进行混合。

对 TimeRole 的意义：与 #18 为不同工作；作为简单基线与效率参照。

[26] FITS: Modeling Time Series with 10k Parameters

2023 | arXiv:2307.03756 | 频域/轻量 | P2 | 风险：低 | 来源级别：C

问题：探索极少参数能否完成长期预测。

核心方法：频域插值与线性映射实现轻量预测。

对 TimeRole 的意义：重要效率基线；有助于避免“模型越复杂越创新”的论证。

[28] TF4TF: Multi-Semantic Modeling within the Time-Frequency Domain for Long-Term Time-Series Forecasting

2025 | Neurocomputing 617, 128913 | 时频/Transformer | P2 | 风险：低 | 来源级别：C

问题：单一时域语义不足以覆盖长期预测中的多种模式。

核心方法：联合 time-frequency 多语义表示并在 Transformer 中交互。

对 TimeRole 的意义：同目标期刊的时频工作；作为 related work 佐证路线拥挤。

3.3 多尺度、Local-Global 与分解建模

[10] MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting

2024 | AAAI | 多尺度/变量关系 | P2 | 风险：低 | 来源级别：C

问题：变量间依赖会随不同时间尺度而变化。

核心方法：从多个尺度建模 inter-series correlation，并结合周期/图式关系。

对 TimeRole 的意义：如果近期分支保留图或多尺度，需用于对照；不直接涉及远历史修正职责。

[11] Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks (LSTNet)

2018 | ACM SIGIR | 长短模式 | P0 | 风险：高 | 来源级别：C

DOI/标识：10.1145/3209978.3210006

问题：短期局部依赖与长期周期模式具有不同性质。

核心方法：结合 CNN、RNN/GRU 与自回归分支，同时捕获短期和长期模式。

对 TimeRole 的意义：“long vs short modeling”早已存在；TimeRole 必须强调 long vs short forecasting responsibility。

[12] MICN: Multi-scale Local and Global Context Modeling for Long-term Series Forecasting

2023 | ICLR | Local-Global | P0 | 风险：高 | 来源级别：C

问题：长期预测中局部细节与全局上下文难以同时高效捕获。

核心方法：多尺度卷积结构联合 local pattern 与 global correlation。

对 TimeRole 的意义：与近期/远期信息分工接近，但仍属于并行 local-global representation，而非主预测/条件修正。

[13] Rethinking Decomposition for Time Series Forecasting: Learning from Temporal Patterns

2025 | Expert Systems with Applications 287, 128044 | 分解/模式专门化 | P0 | 风险：高 | 来源级别：C

问题：固定或机械的 trend-seasonal 分解未必与真正预测相关的 temporal patterns 对齐。

核心方法：从 temporal patterns 出发重新组织分解与预测模块，使不同模式获得更匹配的建模。

对 TimeRole 的意义：上层思想与 TimeRole 接近：不同 temporal information 采用不同职责；需强调划分维度与非对称预测角色。

[14] Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting

2024 | ICLR | 多尺度/自适应路径 | P0 | 风险：高 | 来源级别：C

问题：不同样本需要不同时间尺度与不同 temporal distance 的建模路径。

核心方法：多尺度 patching + adaptive pathways，动态选择不同尺度专家/路径。

对 TimeRole 的意义：直接覆盖 temporal distance 与自适应多尺度；TimeRole 不能声称“首次考虑不同距离”，应强调职责而非距离本身。

[15] Multi-Resolution Time-Series Transformer for Long-Term Forecasting (MTST)

2024 | AISTATS, PMLR 238 | 多分辨率 | P1 | 风险：中 | 来源级别：C

问题：单一 patch 粒度无法充分覆盖快慢变化。

核心方法：多分辨率分支以不同 patch/分辨率表征 fine/coarse temporal patterns。

对 TimeRole 的意义：与远近历史的尺度差异相关，但仍是并行 multi-resolution representation。

[17] TimeSQL: Improving Multivariate Time Series Forecasting with Multi-Scale Patching and Smooth Quadratic Loss

2024 | Information Sciences 671, 120652 | 多尺度/Patch | P1 | 风险：中 | 来源级别：C

DOI/标识：10.1016/j.ins.2024.120652

问题：固定 patch 难以同时适应不同时间尺度，预测损失也需增强鲁棒性。

核心方法：多尺度 patching + smooth quadratic loss。

对 TimeRole 的意义：再次说明多尺度 Patch 已拥挤；TimeRole 的主要贡献不能落在 patch 设计。

[20] Adaptive Multi-Scale Decomposition Framework for Time Series Forecasting (AMD)

2025 | AAAI | 多尺度/分解 | P1 | 风险：中 | 来源级别：C

问题：固定分解尺度无法适应不同数据和 regime。

核心方法：学习自适应多尺度分解，并进行依赖交互和多预测器综合。

对 TimeRole 的意义：直接限制“自适应多尺度分解”创新；TimeRole 应避免把 adaptive split 当作主要卖点。

[21] MSPatch: A Multi-Scale Patch Mixing Framework for Multivariate Time Series Forecasting

2025 | Expert Systems with Applications 273, 126849 | 多尺度/Patch | P1 | 风险：中 | 来源级别：C

DOI/标识：10.1016/j.eswa.2025.126849

问题：单尺度 patch 无法兼顾短期波动与长期模式。

核心方法：多尺度 patch mixing 实现跨尺度信息交互。

对 TimeRole 的意义：与短期主干的 long/short patch 设计高度相关；应作为已有工作边界。

[22] A Multi-Scale Decomposition MLP-Mixer for Time Series Analysis (MSD-Mixer)

2024 | PVLDB 17(7), 1723-1736 | 多尺度/MLP | P2 | 风险：低 | 来源级别：C

DOI/标识：10.14778/3654621.3654637

问题：多尺度结构和趋势变化需要高效非注意力建模。

核心方法：多尺度 decomposition + MLP mixing，并对多层尺度信息进行交互。

对 TimeRole 的意义：说明“多尺度 + MLP + 分解”已是完整路线。

[23] WPMixer: Efficient Multi-Resolution Mixing for Long-Term Time Series Forecasting

2025 | AAAI | 小波/多分辨率 | P2 | 风险：中 | 来源级别：C

问题：需要以高效方式同时利用多分辨率时间和频率信息。

核心方法：wavelet multi-resolution decomposition + patch/mixing。

对 TimeRole 的意义：与 WaveletMamba/AweHF 一起证明频率/多分辨率分工已非常拥挤。

[24] HDMixer: Hierarchical Dependency with Extendable Patch for Multivariate Time Series Forecasting

2024 | AAAI | Patch/CNN | P3 | 风险：低 | 来源级别：C

问题：固定 patch 和浅层依赖难以充分建模多变量序列。

核心方法：extendable patch 与 hierarchical dependency mixing。

对 TimeRole 的意义：可用于说明复杂 Patch 结构已有大量先例，不宜成为 TimeRole 核心贡献。

[25] MTS-Mixers: Multivariate Time Series Forecasting via Factorized Temporal and Channel Mixing

2023 | arXiv:2302.04501 | MLP/变量 | P3 | 风险：低 | 来源级别：C

问题：时间依赖与 channel dependence 需要解耦建模。

核心方法：factorized temporal mixing + channel mixing。

对 TimeRole 的意义：适合近期预测器的简单备选；不触及远历史职责。

[27] Frequency-Domain MLPs Are More Effective Learners in Time Series Forecasting

2023 | NeurIPS 2023 (Advances in NIPS 36) | 频域/MLP | P3 | 风险：低 | 来源级别：C

问题：时域 MLP 对周期/全局结构利用不足。

核心方法：将主要学习过程放入 frequency domain，用 MLP 高效建模频谱模式。

对 TimeRole 的意义：属于频域路线背景；与 TimeRole 的 historical-position role 正交。

[29] DeformableTST: Transformer for Time Series Forecasting without Over-Reliance on Patching

2024 | NeurIPS | Transformer/Patch 反思 | P1 | 风险：中 | 来源级别：C

问题：过度依赖密集 patching 会带来冗余与效率问题。

核心方法：采用 deformable/sparse temporal selection 聚焦重要时间位置。

对 TimeRole 的意义：对你“短期主干收拢”有直接启示：减少 patch/branch 堆叠。

[30] High-Low Frequency Dynamic Interactive Fusion Network for Multivariate Time Series Forecasting (HiLIN)

2025 | Knowledge-Based Systems 310, 112951 | 高低频分工 | P0 | 风险：高 | 来源级别：C

DOI/标识：10.1016/j.knosys.2024.112951

问题：高低频序列承担不同模式，统一建模会相互干扰。

核心方法：高低频分离后以专门模块建模并动态交互融合。

对 TimeRole 的意义：与 TimeRole 的“职责分化”在哲学上很近，但其职责由频率定义；TimeRole 应由历史位置与条件修正定义。

[68] DecompNet: Enhancing Time Series Forecasting Models with Implicit Decomposition

2025 | NeurIPS | 分解增强 | P2 | 风险：低 | 来源级别：B

DOI/标识：10.52202/085713-1083

问题：显式 decomposition 能提升预测但可能引入额外推理成本。

核心方法：将 decomposition knowledge 转为 implicit enhancement，使基础模型推理时无需真正分解即可受益。

对 TimeRole 的意义：说明 decomposition enhancement 也已走向 model-agnostic plug-in；进一步支持 TimeRole 不应以分解模块为主贡献。

3.4 Graph 与跨变量依赖

[32] Connecting the Dots: Multivariate Time Series Forecasting with Graph Neural Networks (MTGNN)

2020 | ACM SIGKDD | Graph/MTS | P1 | 风险：低 | 来源级别：C

问题：变量关系未知且会影响多变量预测。

核心方法：自适应学习图结构并结合 temporal convolution 进行预测。

对 TimeRole 的意义：若保留 Graph 近期主干，这是基础图预测 baseline。

[33] Graph WaveNet for Deep Spatial-Temporal Graph Modeling

2019 | IJCAI | Graph/时空 | P2 | 风险：低 | 来源级别：C

问题：预定义图不完整，时空依赖需要联合建模。

核心方法：adaptive adjacency + dilated temporal convolution。

对 TimeRole 的意义：动态图/自适应图经典工作；Graph 分支应引用。

[34] Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting (AGCRN)

2020 | NeurIPS | Graph/自适应 | P2 | 风险：低 | 来源级别：C

问题：固定图难以捕获节点特异性和隐式关系。

核心方法：node adaptive parameter learning + adaptive graph convolution recurrent network。

对 TimeRole 的意义：是 adaptive graph 的强基础工作。

[35] Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting (STGCN)

2018 | IJCAI | Graph/时空 | P3 | 风险：低 | 来源级别：C

问题：交通序列同时受空间拓扑和时间依赖影响。

核心方法：图卷积与时间卷积联合建模。

对 TimeRole 的意义：时空图网络基础文献，主要用于图分支背景。

[36] Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting (DCRNN)

2018 | ICLR | Graph/RNN | P3 | 风险：低 | 来源级别：C

问题：交通传播具有方向性空间扩散和时间动态。

核心方法：diffusion graph convolution + recurrent encoder-decoder。

对 TimeRole 的意义：Graph+temporal 经典基线。

[37] Global-Local Feature Learning via Dynamic Spatial-Temporal Graph Neural Network in Meteorological Prediction

2024 | IEEE Transactions on Knowledge and Data Engineering | Global-Local/Graph | P2 | 风险：中 | 来源级别：C

问题：气象预测需要同时学习 global/local 时空特征及其动态图关系。

核心方法：动态图神经网络联合 global-local feature learning。

对 TimeRole 的意义：说明 global/local + dynamic graph 已有成熟组合；TimeRole 不宜停留在此。

[38] M2AST: MLP-Mixer-Based Adaptive Spatial-Temporal Graph Learning for Human Motion Prediction

2024 | Multimedia Systems 30(4), 206 | Graph/Mixer | P3 | 风险：低 | 来源级别：C

问题：时空图的多尺度依赖需要轻量且自适应的关系建模。

核心方法：MLP-Mixer 与 adaptive spatial-temporal graph learning 结合。

对 TimeRole 的意义：属于结构参考，与你核心问题间接相关。

[39] Spatial-Temporal Identity: A Simple yet Effective Baseline for Multivariate Time Series Forecasting (STID)

2022 | ACM CIKM | 简单时空基线 | P2 | 风险：低 | 来源级别：C

问题：复杂时空结构可能掩盖简单身份/时间先验的强作用。

核心方法：利用可学习的 spatial/temporal identity embedding 构造极简强基线。

对 TimeRole 的意义：如果近期主干保留图，这是检验“复杂图模块是否必要”的关键简基线。

3.5 Mamba / SSM 与长历史有效窗口

[40] Mamba: Linear-Time Sequence Modeling with Selective State Spaces

2023 | arXiv:2312.00752 | Mamba/SSM | P1 | 风险：中 | 来源级别：B

DOI/标识：10.48550/arXiv.2312.00752

问题：传统序列模型难以在选择性信息传播与线性复杂度间兼顾。

核心方法：让 SSM 参数随输入变化，实现 selective propagation/forgetting 与硬件友好并行扫描。

对 TimeRole 的意义：为“选择性利用历史”提供理论背景，但 selective SSM 本身不是 TimeRole 新颖性。

[41] Efficiently Modeling Long Sequences with Structured State Spaces (S4)

2022 | ICLR | SSM 基础 | P2 | 风险：低 | 来源级别：B

问题：传统 SSM 在超长序列上的计算与稳定性问题。

核心方法：结构化参数化状态矩阵并高效计算卷积核，奠定深度 SSM 长依赖建模基础。

对 TimeRole 的意义：作为 SSM 理论背景；非直接竞争。

[42] Effectively Modeling Time Series with Simple Discrete State Spaces (SpaceTime)

2023 | ICLR | SSM/时间序列 | P2 | 风险：低 | 来源级别：B

问题：现有深度 SSM 对自回归过程表达与长 horizon 预测存在限制。

核心方法：companion-matrix SSM + closed-loop forecasting，提高时间序列表达性和长预测能力。

对 TimeRole 的意义：是 TS+SSM 的关键前置工作，可用于说明 SSM 并非从 Mamba 才进入 TSF。

[43] Is Mamba Effective for Time Series Forecasting? (S-Mamba)

2025 | Neurocomputing 619, 129178 | Mamba/MTS | P1 | 风险：中 | 来源级别：B

DOI/标识：10.1016/j.neucom.2024.129178

问题：验证 Mamba 是否能以较低复杂度完成多变量预测。

核心方法：线性 tokenization + bidirectional Mamba 学习 inter-variate correlation + FFN 学习时间依赖。

对 TimeRole 的意义：Mamba 近期主干必跑/必引；Graph-Mamba 或 Bi-Mamba 不能单独视为核心创新。

[44] TimeMachine: A Time Series is Worth 4 Mambas for Long-Term Forecasting

2024 | ECAI 2024, FAIA 392:1688-1695 | Mamba/多尺度 | P1 | 风险：高 | 来源级别：B

DOI/标识：10.3233/FAIA240677

问题：单一路径难以同时覆盖 channel mixing/independence 与多尺度上下文。

核心方法：以四个 Mamba block 组织多层信息，兼顾多尺度与全局/局部上下文。

对 TimeRole 的意义：直接限制“多尺度 Mamba + global/local”作为主创新的空间。

[45] ms-Mamba: Multi-scale Mamba for Time-Series Forecasting

2026 | Neurocomputing 680, 133226 | Mamba/多尺度 | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1016/j.neucom.2026.133226

问题：单尺度 Mamba 对多时间尺度信号不够充分。

核心方法：多个不同 sampling rate 的 Mamba blocks 对不同 temporal scales 建模。

对 TimeRole 的意义：long/short patch + Mamba 已有直接近邻；TimeRole 必须落在职责机制。

[46] SSMGNN: Spectral Temporal Graph Neural Network with State Space Models for Multivariate Time-Series Forecasting

2026 | Neurocomputing 666, 132295 | SSM/Graph | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1016/j.neucom.2025.132295

问题：传统 GNN 空间/时间模块解耦，静态频谱滤波对局部扰动不适应。

核心方法：从 SSM spectral transfer function 构造动态滤波，并与静态 Fourier Graph Operator 形成 HFGO。

对 TimeRole 的意义：若保留 Graph+SSM 近期主干，这是核心近期工作；Graph+SSM 不能当主创新。

[47] Graph-Enhanced Mamba: Efficient Spatiotemporal Sequence Modeling with Selective State Space and Graph Neural Networks

2026 | Neurocomputing 680, 133280 | Mamba/Graph | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1016/j.neucom.2026.133280

问题：Mamba 长记忆缺乏拓扑约束，图传播又难以高效建模长依赖。

核心方法：Graph-conditioned selective state updates + static/dynamic adjacency + gated spatiotemporal coupling。

对 TimeRole 的意义：与你可能的 Graph-Mamba backbone 高度重叠；建议仅作为近期预测器而非核心贡献。

[48] Attractor Memory for Long-Term Time Series Forecasting: A Chaos Perspective (Attraos)

2024 | NeurIPS | Historical Memory | P0 | 风险：高 | 来源级别：B

DOI/标识：10.52202/079017-0655

问题：长预测不仅是离散相关性问题，还涉及潜在连续动力系统的历史结构。

核心方法：Phase Space Reconstruction + multi-resolution dynamic memory 记忆历史动力结构，再用 frequency-enhanced local evolution 预测。

对 TimeRole 的意义：“historical memory + local evolution”与 TimeRole 非常接近；需强调 TimeRole 的 distant history 只承担条件修正。

[49] Enhancing the Maximum Effective Window for Long-Term Time Series Forecasting

2025 | NeurIPS | 长历史/有效窗口 | P0 | 风险：高 | 来源级别：B

DOI/标识：10.52202/085713-2817

问题：更长 lookback 会引入噪声、冗余、attention dispersion 与过拟合，导致历史利用存在上限。

核心方法：提出 Maximum Effective Window；Information Bottleneck Filter 提取关键子序列，Hybrid Transformer-Mamba 选择性遗忘。

对 TimeRole 的意义：为 TimeRole 提供极强动机：远历史不应与近期历史等价输入主预测器，而应被选择性利用。

[50] MambaTS: Improved Selective State Space Models for Long-Term Time Series Forecasting

2026 | Pattern Recognition, article 114536 | Mamba/MTS | P1 | 风险：中 | 来源级别：B

DOI/标识：10.1016/j.patcog.2026.114536

问题：原始 Mamba 在 LTSF 中存在变量扫描顺序、因果卷积和过拟合等问题。

核心方法：Variable-Aware Scan along Time + Temporal Mamba Block + selective dropout。

对 TimeRole 的意义：进一步压缩“改 Mamba 扫描/变量关系”作为主创新的空间。

[51] WaveletMamba: Harnessing Learnable Multi-Scale State Space Dynamics for Time Series Forecasting

2026 | Neural Networks 204, 109296 | Mamba/频率多尺度 | P1 | 风险：高 | 来源级别：B

DOI/标识：10.1016/j.neunet.2026.109296

问题：需要同时处理多尺度频率模式、长依赖和多变量交互。

核心方法：learnable Haar-like multi-scale module + Temporal Mamba Refinement。

对 TimeRole 的意义：Wavelet + multi-scale + Mamba 已经形成完整路线；TimeRole 应避免频率分解式主张。

[52] Transformers Are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality (Mamba-2)

2024 | ICML, PMLR 235 | SSM 理论 | P3 | 风险：低 | 来源级别：B

问题：解释 attention 与 SSM 的结构联系并提高 Mamba 计算效率。

核心方法：State Space Duality 框架，提出更高效的 Mamba-2。

对 TimeRole 的意义：理论背景/实现选择参考，不直接冲突 TimeRole。

3.6 Historical Memory / Retrieval-Augmented Forecasting

[53] Predicting the Future by Retrieving the Past (PFRP)

2026 | AAAI 2026, 40(25):20896-20904 | 历史检索 | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1609/aaai.v40i25.39230

问题：滑窗预测器在推理时只使用局部 lookback，无法显式访问整个历史库。

核心方法：Global Memory Bank 存储 past/future patterns；检索相似历史产生 global prediction，与任意 local predictor 自适应组合。

对 TimeRole 的意义：当前最直接竞争之一：global historical evidence + local prediction。TimeRole 必须强调 within-input distant history、从属式 correction 而非并行 global prediction。

[54] Retrieval Augmented Time Series Forecasting (RAFT)

2025 | ICML, PMLR 267:21774-21797 | 历史检索 | P0 | 风险：高 | 来源级别：B

问题：纯参数模型未充分利用训练集中可直接复用的历史模式。

核心方法：检索与当前输入最相似的历史样本，并将这些样本对应的 future values 与当前输入一起用于预测。

对 TimeRole 的意义：证明“选择相关历史再预测”已成明确路线；TimeRole 应区别为固定输入历史的职责分化，而非外部数据库检索。

[55] TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting

2025 | IEEE Transactions on Knowledge and Data Engineering | 历史检索/基础模型 | P1 | 风险：中 | 来源级别：B

DOI/标识：10.1109/TKDE.2025.3579137

问题：时间序列基础模型零样本预测缺乏任务特定外部知识。

核心方法：构造 task-specific knowledge base，端到端 retriever 检索历史知识，通过 Channel Prompting 融合。

对 TimeRole 的意义：外部历史知识增强路线的重要工作；与 TimeRole 的 within-window correction 不同。

[56] Retrieval-Augmented Diffusion Models for Time Series Forecasting (RATD)

2024 | NeurIPS | 历史检索/生成 | P1 | 风险：中 | 来源级别：B

问题：时间序列 diffusion 受数据量和条件 guidance 不足影响。

核心方法：embedding retrieval 找相关历史 reference，并用 reference-guided diffusion 进行条件生成。

对 TimeRole 的意义：说明 historical reference 可作为“指导信息”而非主预测输入，与 TimeRole correction 逻辑有可比性。

[57] Stationarity-Aware Retrieval-Augmented Time Series Forecasting (SARAF)

2026 | KDD 2026 (Research Track, accepted/in press) | 历史检索/非平稳 | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1145/3770855.3817813

问题：“相似过去 -> 相似未来”在非平稳序列中不可靠。

核心方法：stationarity-aware candidate retrieval、diversity-aware selection 与 stationarity-aware aggregation，覆盖不同 historical regimes。

对 TimeRole 的意义：对“什么时候远历史有用”极有启发：TimeRole 应考虑 regime/状态条件化，而不只是时间距离。

[58] GeMeR-TS: Generative Memory-Based Retrieval and Mixture-of-Experts for Cross-Domain Time-Series Forecasting

2026 | IEEE Transactions on Big Data 12(4):1401-1419 | Memory/Retrieval | P1 | 风险：中 | 来源级别：B

DOI/标识：10.1109/TBDATA.2026.3689009

问题：跨域预测需要可迁移、可检索的历史 prototype 与专家组合。

核心方法：generative/differentiable memory retrieval + Mixture-of-Experts。

对 TimeRole 的意义：说明“memory module + retrieval”本身已不新；TimeRole 应突出 temporal responsibility 与 correction semantics。

[63] Retrieval Augmented Forecasting (RAF)

2024 | arXiv:2411.08249 | 历史检索/基础模型 | P3 | 风险：中 | 来源级别：B

DOI/标识：10.48550/arXiv.2411.08249

问题：时间序列 foundation model 在跨域/事件驱动场景需要外部历史增强。

核心方法：设计 time-series retrieval 与 aggregation 机制，将相关历史样本注入基础模型预测。

对 TimeRole 的意义：观察池：帮助界定 retrieval 与 within-input historical responsibility 的差异。

[64] Semantics-Enhanced Retrieval-Augmented Time Series Forecasting (SERAF)

2026 | arXiv:2606.14941 | 历史检索/语义 | P3 | 风险：中 | 来源级别：B

DOI/标识：10.48550/arXiv.2606.14941

问题：仅凭数值相似性检索在非平稳场景不稳健。

核心方法：同时对数值序列与自动生成的文本语义进行双路 retrieval，再选择性联合相关历史 futures。

对 TimeRole 的意义：观察池：表明历史选择正在从单一相似度走向多条件检索；TimeRole 的 correction gate 也应具备状态条件。

[65] Model-Agnostic Retrieval-Augmented Extended Forecasting for Time Series (RAEF)

2026 | arXiv:2608.14054 | 历史检索/模型无关 | P3 | 风险：中 | 来源级别：B

DOI/标识：10.48550/arXiv.2608.14054

问题：foundation model 的 RAG 需要降低检索开销并更好保留时序结构。

核心方法：在 RAF 基础上改为 input-space direct retrieval 与 concatenation-based aggregation。

对 TimeRole 的意义：观察池：非常新，说明模型无关 historical augmentation 正快速发展。

[67] How Different from the Past? Spatio-Temporal Time Series Forecasting with Self-Supervised Deviation Learning (ST-SSDL)

2025 | NeurIPS | Historical Deviation | P1 | 风险：中 | 来源级别：B

DOI/标识：10.52202/085713-4905

问题：当前输入相对历史典型模式的偏离本身是重要预测信号。

核心方法：以 historical average/prototypes 作为锚点，自监督学习当前输入与历史模式的 deviation，并联合预测目标优化。

对 TimeRole 的意义：对 TimeRole 的 correction trigger 很有启发：远历史是否应修正，可以由“当前状态相对历史 regime 的偏离”刻画。

3.7 Base Forecast 、Residual 、Refinement 与 Revision

[31] Multi-Granularity Residual Learning with Confidence Estimation for Time Series Prediction

2022 | The Web Conference (WWW) | 残差/多粒度 | P0 | 风险：高 | 来源级别：C

DOI/标识：10.1145/3485447.3512056

问题：粗粒度预测与细粒度变化之间存在可利用的残差信息。

核心方法：通过 multi-granularity representation 和 residual learning/置信度估计进行细化。

对 TimeRole 的意义：与“基础预测 + 修正”非常接近；TimeRole 必须把 correction 的来源与职责限定在 distant history。

[59] xLSTM-Mixer: Multivariate Time Series Forecasting by Mixing via Scalar Memories

2025 | NeurIPS | Forecast Refinement | P0 | 风险：高 | 来源级别：B

DOI/标识：10.52202/085713-0228

问题：简单线性预测难以覆盖复杂动态，但可作为稳定基础。

核心方法：先生成共享线性 forecast，再由 xLSTM blocks refinement，并融合多个视角。

对 TimeRole 的意义：“base forecast + refinement”已被明确采用；TimeRole 创新必须落在 distant-history-conditioned refinement。

[60] MCNet: Multivariate Long-Term Time Series Forecasting with Local and Global Context Modeling

2024 | Information Sciences 676, 120864 | Local-Global | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1016/j.ins.2024.120864

问题：长期预测需要同时处理最近局部细节、变量关系与全局长依赖。

核心方法：local branch 对最近序列 patch 做 MLP/通道交互，global branch 对整段序列做结构化全局卷积。

对 TimeRole 的意义：非常接近 recent/local vs global/long branch，但二者是联合预测证据；TimeRole 应强调主从职责和 correction gating。

[61] Stratify: Unifying Multi-Step Forecasting Strategies

2025 | Data Mining and Knowledge Discovery 39, article 64 | Residual Rectification | P0 | 风险：高 | 来源级别：B

DOI/标识：10.1007/s10618-025-01135-1

问题：多步预测存在多种 recursive/direct/multi-output/rectify 策略，缺乏统一框架。

核心方法：将 Rectify 泛化为可组合 base strategy + residual rectifier strategy 的参数化空间。

对 TimeRole 的意义：说明“base + residual rectifier”是成熟预测策略；TimeRole 不能只以两阶段残差修正为新颖性。

[62] GARS: Gap-Aware Residual Selection for Long-Horizon Time-Series Forecasting

2026 | Preprints.org, posted 2026-08-04 | Residual Correction | P0 | 风险：高 | 来源级别：B

问题：固定 forecast-generation 对不同输入实例不够自适应。

核心方法：插件式 refinement：initial forecast + gap-aware residual + direct residual，并沿 horizon 分段软加权。

对 TimeRole 的意义：虽然仍是预印本，但与“基础预测 + 条件修正”功能形式非常接近，投稿前必须持续追踪。

[66] Improving Time Series Forecasting via Instance-Aware Post-hoc Revision (PIR)

2025 | NeurIPS | Post-hoc Revision | P0 | 风险：高 | 来源级别：B

DOI/标识：10.52202/085713-1196

问题：总体性能良好的模型仍会因分布漂移、缺失和长尾导致特定实例预测偏差。

核心方法：Post-forecasting Identification and Revision：先识别可能偏置的 forecast instance，再利用 covariates 与 local/global historical context 后处理修正。

对 TimeRole 的意义：这是 TimeRole 极重要近邻：历史信息直接用于 forecast revision。TimeRole 应区别为端到端的 temporal-role design，而非预测后错误识别与后处理。

4. 对 TimeRole 创新边界的综合判断

判断项	结论
不能作为主创新的内容	单纯 long/short dual branch; 多尺度 patch; series decomposition; Graph + Mamba; bidirectional Mamba; local/global parallel fusion; generic base forecast + residual correction; external historical retrieval。
更可守住的核心定义	Recent history establishes the predictive state and produces the primary forecast; distant history is treated as subordinate corrective evidence and is activated only when it is conditionally useful given the recent state.
关键区别 1：划分维度	已有工作主要按 scale、frequency、trend/event、local/global、retrieved/not-retrieved 划分信息；TimeRole 应按历史位置与预测职责划分。
关键区别 2：职责非对称	已有双分支通常将不同来源视为平行 evidence 并融合；TimeRole 应明确 recent=primary，distant=correction，且 distant 不应独立承担完整预测。
关键区别 3：条件触发	PFRP/RAFT/SARAF 证明“选择性历史”重要；TimeRole 应进一步设计由 recent state 决定的 correction gate / confidence / discrepancy signal，而不是固定加权。
关键区别 4：纠错语义	DualNet、MRLF、xLSTM-Mixer、Stratify、GARS、PIR 已覆盖 generic refinement。TimeRole 的修正必须可解释为 distant-history-conditioned bias correction，而非任意第二预测器。

4.1 推荐的最小方法表达

建议把方法抽象为下式，而不要先从复杂模块名出发：

Recent state: $H_r = f_r(X_{recent})$

Primary forecast: $Y_{base} = g(H_r)$

Distant memory: $M_d = f_d(X_{distant})$

Conditional correction: $\Delta Y = c(M_d, H_r)$

Adaptive responsibility: $\alpha = a(H_r, M_d)$

Final forecast: $\hat{Y} = Y_{base} + \alpha * \Delta Y$

4.2 建议必须做的关键消融/诊断

- Recent-only：只使用近期历史做主预测，确认主干本身强度。
- Symmetric fusion：把 recent/distant 当成平行分支融合，验证“职责非对称”优于普通双分支。
- No-correction：关闭 distant correction，量化远历史的净收益。

- Random-distant / shuffled-distant: 打乱或替换远历史, 验证 correction 依赖真实历史证据而非增加参数。
- Distance-bin sweep: 按不同远历史距离区间评估修正收益, 证明“远历史职责”随距离/状态变化。
- Gate analysis: 统计 alpha 与 base error、distribution shift、regime deviation 的相关性, 证明 correction 在需要时才激活。
- Lookback/MEW analysis: 比较不同总历史长度和 recent/distant 切分, 连接 Maximum Effective Window 文献。
- Backbone swap: 用 DLinear/MLP/S-Mamba 等不同 recent predictor 替换主干, 证明 TimeRole 是 model-agnostic 机制而非某个 backbone 特例。
- Complexity/latency: 报告参数量、FLOPs/推理时间, 防止“为了修正而过度堆模块”。

4.3 最优先精读的 15 篇

1. S3 DualNet - 主预测 + 自适应补偿。
2. 53 PFRP - global historical memory + local predictor。
3. 49 MEW - 长历史何时失效及选择性利用。
4. 48 Attraos - historical dynamic memory + local evolution。
5. 66 PIR - post-hoc identification and revision, 直接用 local/global history 修正预测。
6. 31 Multi-Granularity Residual Learning - residual refinement 近邻。
7. 59 xLSTM-Mixer - linear base forecast + xLSTM refinement。
8. 61 Stratify - base + residual rectifier 的一般化预测策略。
9. 60 MCNet - recent/local 与 global/long 双分支。
10. 57 SARAF - 非平稳条件下的历史选择。
11. 54 RAFT - 外部历史检索增强预测。
12. 14 Pathformer - temporal distance + adaptive multi-scale pathway。
13. 30 HiLIN / S5 AweHF - frequency-defined role differentiation。
14. 45 ms-Mamba / 46 SSMGNN / 47 G-Mamba - 收紧 Mamba/Graph backbone 创新空间。
15. 11 LSTNet / 12 MICN - long-short / local-global 建模的经典边界。

5. 推荐的 Related Work 组织方式

5.1 Long-Term and Multivariate Time Series Forecasting

用 DLinear、PatchTST、iTransformer、Crossformer、TimeMixer 交代主流 LTSF/MTSF backbone，不需要铺太多篇。

5.2 Multi-Scale, Local-Global and Decomposition Modeling

集中讨论 LSTNet、MICN、Pathformer、MTST、AMD、MSPatch、HiLIN/AweHF，指出它们主要在 scale/frequency/component 层面做差异化。

5.3 State Space Models and Graph-Enhanced Forecasting

用 S4、SpaceTime、S-Mamba、TimeMachine、ms-Mamba、SSMGNN、G-Mamba 说明近期预测器可采用高效 SSM，但这不是本文核心贡献。

5.4 Historical Memory and Retrieval-Augmented Forecasting

重点放 Attraos、MEW、PFRP、RAFT、TimeRAF、SARAF、GeMeR-TS，明确已有方法如何访问/选择历史。

5.5 Forecast Refinement and Correction

重点放 DualNet、MRLF、xLSTM-Mixer、Stratify、GARS、PIR，然后自然引出：现有 correction 通常来自 residual learner、post-hoc module 或并行/global predictor，而不是把 distant observations 赋予独立的 corrective responsibility。

5.6 可用于 Introduction 的创新缺口表述（工作版本）

现有研究已经从多尺度、频率分解、局部-全局建模和检索增强等角度证明，不同历史信息具有异质性。然而，这些方法通常仍将不同来源的历史表示视为并行或对称的预测证据，或者将额外历史作为外部检索知识用于再次预测。另一方面，残差学习和预测修正方法虽然能够在基础预测之后进一步校准结果，但其修正信号通常并未与历史位置的职责建立明确联系。基于此，我们研究一个不同的问题：不同时间距离的历史观测是否应承担不同的预测职责。TimeRole 让近期历史建立预测状态并生成基础预测，而远期历史仅在近期状态条件下提供选择性的预测修正。

6. 使用说明与下一步

- 这 73 篇不是建议全部写入最终 References。对于一篇 Neurocomputing 风格论文，最终核心引用通常应压缩到约 35-45 篇，并保证每一篇都在正文中承担明确论证作用。
- 优先把 P0 文献全文下载并做逐篇“问题-方法-与 TimeRole 冲突点”精读。P1 用于 Related Work 与 baseline，P2/P3 只在需要补充某条路线时使用。
- 正式投稿前，应再次检查 2026 年新近论文（尤其 GARS、SERAF、RAEF 等预印本/在版文献）的最终出版状态与 DOI。
- 本报告的 C 级文献目前主要基于用户提供的 5 篇 Neurocomputing 论文参考文献与引用语境进行定位；若要直接写入论文中的具体技术比较，需要阅读全文核实方法细节。

附录 A：DOI / 标识索引

编号	论文（简写）	DOI/标识	来源级别
S1	Wrinkles in time: Multi-scale patching and super-resolution for efficient time series forecasting	10.1016/j.neucom.2026.133021	A
S2	DiM: Improving multivariate time series forecasting with DI embedding and multi-head graph learning mechanism	10.1016/j.neucom.2025.131777	A
S3	DualNet: A dual-path network with adaptive compensation for multivariate time series forecasting	10.1016/j.neucom.2025.130720	A
S4	Multi-resolution Patch-based Fourier Graph Spectral Network for spatiotemporal time series forecasting	10.1016/j.neucom.2025.130132	A
S5	Adaptive wavelet decomposition and event-aware high-frequency modeling network for multivariate time series forecasting	10.1016/j.neucom.2026.133089	A
11	Modeling Long- and Short-Term Temporal Patterns with Deep Neural Networks (LSTNet)	10.1145/3209978.3210006	C
17	TimeSQL: Improving Multivariate Time Series Forecasting with Multi-Scale Patching and Smooth Quadratic Loss	10.1016/j.ins.2024.120652	C
21	MSPatch: A Multi-Scale Patch Mixing Framework for Multivariate Time Series Forecasting	10.1016/j.eswa.2025.126849	C
22	A Multi-Scale Decomposition MLP-Mixer for Time Series Analysis (MSD-Mixer)	10.14778/3654621.3654637	C
30	High-Low Frequency Dynamic Interactive Fusion Network for Multivariate Time Series Forecasting (HiLIN)	10.1016/j.knosys.2024.112951	C
31	Multi-Granularity Residual Learning with Confidence Estimation for Time Series Prediction	10.1145/3485447.3512056	C
40	Mamba: Linear-Time Sequence Modeling with Selective State Spaces	10.48550/arXiv.2312.00752	B
43	Is Mamba Effective for Time Series Forecasting? (S-Mamba)	10.1016/j.neucom.2024.129178	B
44	TimeMachine: A Time Series is Worth 4 Mambas for Long-Term Forecasting	10.3233/FAIA240677	B
45	ms-Mamba: Multi-scale Mamba for Time-Series Forecasting	10.1016/j.neucom.2026.133226	B
46	SSMGNN: Spectral Temporal Graph Neural Network with State Space Models for Multivariate Time-Series Forecasting	10.1016/j.neucom.2025.132295	B
47	Graph-Enhanced Mamba: Efficient Spatiotemporal Sequence Modeling with Selective State Space and Graph Neural Networks	10.1016/j.neucom.2026.133280	B
48	Attractor Memory for Long-Term Time Series Forecasting: A Chaos Perspective (Attraos)	10.52202/079017-0655	B
49	Enhancing the Maximum Effective Window for Long-Term Time Series Forecasting	10.52202/085713-2817	B
50	MambaTS: Improved Selective	10.1016/j.patcog.2026.114536	B

	State Space Models for Long-Term Time Series Forecasting		
51	WaveletMamba: Harnessing Learnable Multi-Scale State Space Dynamics for Time Series Forecasting	10.1016/j.neunet.2026.109296	B
53	Predicting the Future by Retrieving the Past (PFRP)	10.1609/aaai.v40i25.39230	B
55	TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting	10.1109/TKDE.2025.3579137	B
57	Stationarity-Aware Retrieval-Augmented Time Series Forecasting (SARAF)	10.1145/3770855.3817813	B
58	GeMeR-TS: Generative Memory-Based Retrieval and Mixture-of-Experts for Cross-Domain Time-Series Forecasting	10.1109/TBDATA.2026.3689009	B
59	xLSTM-Mixer: Multivariate Time Series Forecasting by Mixing via Scalar Memories	10.52202/085713-0228	B
60	MCNet: Multivariate Long-Term Time Series Forecasting with Local and Global Context Modeling	10.1016/j.ins.2024.120864	B
61	Stratify: Unifying Multi-Step Forecasting Strategies	10.1007/s10618-025-01135-1	B
63	Retrieval Augmented Forecasting (RAF)	10.48550/arXiv.2411.08249	B
64	Semantics-Enhanced Retrieval-Augmented Time Series Forecasting (SERAF)	10.48550/arXiv.2606.14941	B
65	Model-Agnostic Retrieval-Augmented Extended Forecasting for Time Series (RAEF)	10.48550/arXiv.2608.14054	B
66	Improving Time Series Forecasting via Instance-Aware Post-hoc Revision (PIR)	10.52202/085713-1196	B
67	How Different from the Past? Spatio-Temporal Time Series Forecasting with Self-Supervised Deviation Learning (ST-SSDL)	10.52202/085713-4905	B
68	DecompNet: Enhancing Time Series Forecasting Models with Implicit Decomposition	10.52202/085713-1083	B

报告结束。